

# 融入自注意力机制的深度学习情感分析方法

胡艳丽 童谭骞 张啸宇 彭娟

国防科技大学信息系统工程重点实验室 长沙 410073

**摘要** 文本情感极性分析是自然语言处理的热点领域,近年来基于中文语料的情感分析方法受到了学术界的广泛关注。目前大部分基于词向量的循环神经网络与卷积神经网络模型对于文本特征的提取和保留能力不足,为此文中引入了多层自注意力机制,提出了一种结合双向门控循环单元(BGRU)和多粒度卷积神经网络的中文情感极性分析方法。该方法首先使用BGRU获取文本的序列化特征信息,然后使用自注意力机制进行初步特征筛选,将处理后的特征信息导入含有不同卷积核的卷积神经网络;再使用自注意力机制对获得的局部特征进行动态权重的调整,注重关键特征的抽取;最后经Softmax获得文本情感极性。实验结果证明,模型在两种中文语料数据集上都体现了较好的分析处理性能,其中在ChineseNLPcorpus的online\_shopping\_10\_cats数据集上取得了92.94%的情感分类准确性,在中科院谭松波学者整理的酒店评论数据集上取得了92.75%的情感分类准确度,相比目前的主流方法,其性能均有显著的提升。

**关键词:**情感分析;自注意力机制;双向门控制循环单元;多粒度卷积神经网络

中图法分类号 TP391

## Self-attention-based BGRU and CNN for Sentiment Analysis

HU Yan-li, TONG Tan-qian, ZHANG Xiao-yu and PENG Juan

Science and Technology on Information Systems Engineering Laboratory, National University of Defense Technology, Changsha 410073, China

**Abstract** Text sentiment analysis is a hot field in natural language processing. In recent years, Chinese text sentiment analysis methods have been widely investigated. Most of the recurrent neural network and convolutional neural network models based on word vectors have insufficient ability to extract and retain text features. In this paper, a Chinese sentiment polarity analysis model combining bi-directional GRU (BGRU) and multi-scale CNN is proposed. First, BGRU is utilized to extract text serialization features filtered with attention mechanism. Then the convolution neural network with distinct convolution kernels is applied to attention mechanism to adjust the dynamic weights. The text is acquired by the Softmax emotional polarity. Experiments indicates that our model outperforms the state-of-the-art methods on Chinese datasets. The accuracy of sentiment classification is 92.94% on the online\_shopping\_10\_cats dataset of ChineseNLPcorpus, and 92.75% on the hotel review dataset compiled by Tan Songbo of Chinese Academy of Sciences, which is significantly improved compared with the current mainstream methods.

**Keywords** Sentiment analysis, Self-attention mechanism, Bi-directional gated recurrent unit, Multi-scale convolution neural network

## 1 研究内容及意义

中国互联网信息中心(CNNIC)2020年9月份的统计报告显示,我国网民规模已达9.4亿,占全球网民总数的1/5。互联网的高速发展和社交网络的无孔不入带来了文本信息爆炸式增长。线上评论文本,如时事评论、在线购物评论、书评影评等文本数据因具有针对性强、价值密度高的特点而受到了学术界的普遍关注<sup>[1]</sup>。针对文本数据的情感分析不仅能起到调剂商业活动、反映受众满意度等作用,而且为监管社情舆论、维护社会稳定提供了重要支撑,具有较高的商业价值和重要的社会价值。

神经网络方法具有优越的文本特征学习能力。Blunsom等<sup>[2]</sup>在对Twitter文本进行情感分析时引入了卷积神经网络(Convolutional Neural Networks, CNN);Kim<sup>[3]</sup>采用多种卷积核的卷积神经网络来提取文本特征,用于处理句子级别的文本任务。但这些方法未考虑上下文信息对情感极性的影响。Liu<sup>[4]</sup>提出了双向LSTM(Bi-LSTM)模型,用于提取语句级语义粒度信息。为了实现文本特征的动态赋权,提高关键特征,注意力模型也被引入NLP领域。Wang等<sup>[5]</sup>采用注意力向量对两个LSTM进行拼接匹配,然后进行预测分析,很好地解决了短文本分类问题。但是,该类研究只是将注意力机制堆叠在循环神经网络(Recurrent Neural Network, RNN)

到稿日期:2021-06-04 返修日期:2021-09-10

基金项目:国家自然科学基金(61302144, 61902417)

This work was supported by the National Natural Science Foundation of China(61302144, 61902417).

通信作者:胡艳丽(huyanli@nudt.edu.cn)

后,在局部特征处理方面仍采用较固化的池化方法。

针对上述问题,本文提出了一种基于层次自注意力的深度学习情感分析模型。首先使用双向门控循环单元(Bidirectional Gated Recurrent Unit,BGRU)提取文本序列特征;然后采用注意力机制(attention mechanism),结合全局信息对特征进行初步筛选,通过不同粒度的卷积核对局部特征进行多维度提取;再使用自注意力机制对局部特征进行动态赋权与提取保留,突出情感极性相关度高的特征,提高模型的判断准确性;最后通过 Softmax 完成文本情感分类。

本文的主要贡献如下:

(1)提出了一种门控制循环单元与卷积神经网络结合的模式。对数据的序列特征和局部特征进行充分挖掘,以获取文本内部结构的关系。

(2)设计层次自注意力机制。在循环神经网络与卷积神经网络中分别引入自注意力机制,实验结果表明,该策略能提高模型对文本特征的筛选和保留的能力。

## 2 相关工作

### 2.1 情感分析

情感分析(sentiment analysis)也被称为情感倾向性分析,最早由 Li 等<sup>[6]</sup>提出,逐渐成为自然语言处理(Natural Language Processing,NLP)的热门领域。文本情感分析源于文本分类,可以理解为一种以情感倾向为判断标准的特殊文本分类问题。在文本情感分析任务中,又以情感极性分析为主要研究方向。情感极性分析,顾名思义,一般表现为二分类问题。通过特定的处理算法将文本中所蕴含的情感分为正倾向和负倾向,在少数情况下会划分为 3 种结果,即加入情感中性倾向这一情况。正倾向包含满意、兴奋、赞叹等积极情感,而悲伤、失落、怨恨等则归为负倾向。Pang 等<sup>[7]</sup>利用机器学习方法对电影评论数据进行情感极性分析,取得了一定成果。Hu 等<sup>[8]</sup>结合词组的情感极性来判断文本的情感倾向。Yao 等<sup>[9]</sup>用句法分析的办法来判断情感极性。Dai 等<sup>[10]</sup>提出了一种基于 Spark 分布式系统的集成情感大数据分析方案。

随着计算机技术的不断发展和数据规模的急速膨胀,目前基于情感词典和基于有监督的机器学习的方法正逐渐被基于弱监督的深度学习方案所取代。基于情感词典的方法以词典为核心,处理及分析的过程简单,便于理解,这是该方案的优势,也是其实际应用的最大局限。互联网迅猛发展,层出不穷的网络词汇不断涌现,已有的情感词典无法完全包含文本中各词的情感标签,导致情感极性的分类性能下降,而建立实时更新的情感词典又极其消耗人力物力。目前多数基于机器学习的分析方案仍依赖人工方式建立特征工程,这一点不仅制约了机器学习方案在不同领域任务之间的发展,而且以人的主观判断建立的特征工程也存在缺乏解释性和稳定性较弱的问题。

近年来,深度学习的发展推动了文本情感分析技术的革新。相比传统方案,基于深度学习的分析模型因其轻量化的预处理和可以自动提取情感特征工程的特点在情感极性分析中取得了长足的进步。但是,基于深度学习的方法仍存在着诸多不足。部分神经网络结构自身利弊共存:例如,循环神经网络

在处理文本序列信息时有着不错的表现,但囿于自身构造,在模型训练时存在过拟合的风险,训练速度较低、梯度爆炸和梯度弥散等问题也经常出现;卷积神经网络最早在计算机视觉领域被提出,之后对局部特征具有较强的提取能力,在文本情感分析任务中也得到了广泛使用,但是该网络因其结构难以分析文本的整体结构信息,容易产生语义肢解的情况。Bowman 等<sup>[11]</sup>提出了能够解决长程依赖问题的长短时记忆网络(Long Short-Term Memory,LSTM);Rocktäschel 等<sup>[12]</sup>使用两个独立的 LSTM 来充分挖掘文本信息;Xiao 等<sup>[13]</sup>使用双向 LSTM 结构对中文文本进行情感判断;Pappas 等<sup>[14]</sup>采用多层次注意力机制与双向门控循环单元相结合的方法,提高了文本分类的准确性;Liu 等<sup>[15]</sup>针对微博评论数据,采用卷积神经网络进行情感极性分析,增强了对文本局部特征的提取能力。针对基于用户评论的方面级别细粒度情感分析任务,Zhang 等<sup>[16]</sup>提出了注意力机制与门控机制相结合的文本情感分类模型。

组合使用循环神经网络和卷积神经网络可以提高模型的泛化能力和准确性。Yuan 等<sup>[17]</sup>提出了加入注意力机制的多粒度卷积与 BGRU 的模型,在 BGRU 后加入注意力机制以提高对关键信息的把握。Wang 等<sup>[18]</sup>使用双通道复合网络的方式对中文的文本情感进行分析,但在池化层方面仍采用传统的 Pooling 方法,对局部特征的抽取保留较为粗糙,导致与情感极性相关的特征被丢弃,影响了分类的准确性。

### 2.2 注意力机制

注意力机制源于对人类视觉处理机制的研究。在人认知世界的过程中,大脑的处理策略总是选择性地关注某些知识,而忽略掉或淡化其他信息,这便是人类的注意力机制。计算机的注意力机制源于仿生学的发展,其机理可理解为结合内外部信息以加速提取稀疏数据的重要特征。

Mnih 等<sup>[19]</sup>在图像分类任务中首次应用注意力机制来筛选数据特征,有效提高了分类效果。Bahdanau 等将注意力机制用于处理机器翻译任务<sup>[20]</sup>,是注意力机制在 NLP 领域进行应用的开端。Cheng 等<sup>[21]</sup>发现采用如 LSTM 等方法进行文本分类时,随着输入文本长度的增加,编码中间向量带来的信息损失也会急剧增加,降低分类的精确性,而注意力机制可以有效地缓解此类问题。

自注意力机制是注意力机制的一种改进,降低了对外部信息的依赖程度,提高了对数据特征的内部相关性的捕捉能力。本文采用自注意力机制,提高了对文本情感极性相关特征的关注度,进而提高了分类准确性。

### 2.3 门控循环单元

2014 年,Cho 等<sup>[22]</sup>提出了门控制循环单元(GRU)。GRU 与 LSTM 同为对循环神经网络的改进。GRU 模型包含更新门和重置门两种门结构。重置门决定了如何将新的输入信息与前面的记忆相结合,更新门定义了前面记忆保存到当前时间步的量。因采用了更加精简的结构,GRU 模型的训练速度较 LSTM 有一定的提升,能够更好地对文本进行表征和建模。

设在  $t$  时刻,输入为  $x_t$ ,GRU 隐藏层的输出为  $h_t$ ,计算

过程如式(1)一式(4)所示:

$$z_t = \sigma(\mathbf{W}_z[h_{t-1}, x_t]) \quad (1)$$

$$r_t = \sigma(\mathbf{W}_r[h_{t-1}, s_t]) \quad (2)$$

$$\bar{h}_t = \tanh(\mathbf{W}[r_t * h_{t-1}, s_t]) \quad (3)$$

$$h_t = (1 - z_t) * h_{t-1} + z_t * \bar{h}_t \quad (4)$$

其中,  $\mathbf{W}$  为连接两层的权重矩阵, 下标  $r, z$  表示重置门和更新门,  $\tanh$  和  $\sigma$  表示激活函数。

本文模型采用双向门控制循环单元对数据进行提取, 充分考虑了文本的序列信息, 提高了情感判断的准确性。

### 3 融入自注意力机制的深度学习情感分析方法

本文提出了融入自注意力机制的深度学习情感分析方法

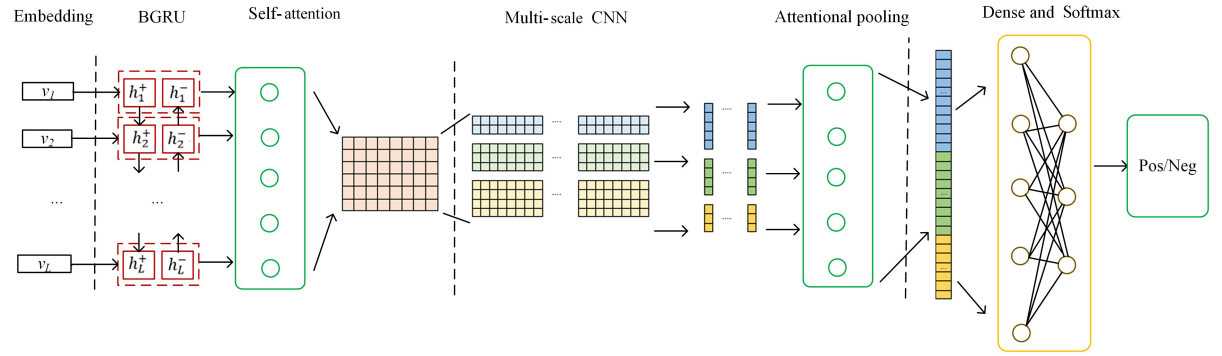


图1 融入自注意力机制的深度学习情感分析方法

Fig. 1 Self-attention-based BGRU and CNN for sentiment analysis

本文模型先使用分词模块对文本进行分词, 再经词向量映射, 将中文词语转化为实数向量。本文模型首先使用双向 GRU 对文本序列特征进行分析, 获得语句的内部结构信息, 通过自注意力层对特征进行动态赋权, 突出关键特征。然后, 将特征序列导入多粒度卷积层, 提取不同尺度的局部特征。在卷积层后再次加入自注意力机制, 赋予与情感极性判断相关性高的特征更大的权重, 最后通过分类器得到情感极性的分类结果。

#### 3.2 处理流程

组合使用循环神经网络和卷积神经网络, 先使用循环神经网络对文本的序列特征进行初步提取, 再导入卷积网络进行局部特征抽取, 设文本输入为  $D$ , 经文本预处理步骤, 对文本数据进行繁简统一, 并剔除标点等特殊字符, 得到输出  $D'$ 。

##### 3.2.1 词嵌入层(embedding layer)

使用分词模块将  $D'$  转化为词序列。假设该序列由  $L$  个词组成, 即将文本数据输入表示为  $\{w_1, w_2, w_3, \dots, w_i, \dots, w_L\}$ , 然后通过预训练词向量模型对词序列进行词向量映射, 并将其转化为词向量序  $\{v_1, v_2, v_3, \dots, v_i, \dots, v_L\}$ ,  $v_i \in R^d$ ,  $d$  表示每个词的维度。

##### 3.2.2 BGRU 层(BGRU layer)

将词向量序列输入双向门限循环单元, 学习文本序列化特征。该步骤的运算过程可表示为: 分别经一个正向 GRU 和一个反向 GRU, 然后对输出进行组合, 计算过程如式(5)一式(7)所示:

$$h_t^+ = f_{\text{GRU}}(h_{t-1}, v_t) \quad (5)$$

法, 该方法采用下列机制来提高性能和鲁棒性。

(1) 组合使用循环神经网络和卷积神经网络, 使用循环神经网络对文本的序列特征进行初步提取, 再导入卷积网络进行局部特征抽取。

(2) 使用多种粒度的卷积核对文本不同尺度的特征进行提取, 充分挖掘文本不同尺度的特征信息。

(3) 用自注意力机制取代传统的池化方法, 提高对关键局部向量的提取保留能力。

#### 3.1 模型构造

本文模型主要分为词嵌入层、BGRU 层、自注意力层、多粒度卷积层、基于自注意力的池化层以及全连接与分类层 6 个层次, 如图 1 所示。

$$h_t^- = f_{\text{GRU}}(h_{t-1}, v_t) \quad (6)$$

$$h_t = [h_t^+, h_t^-] \quad (7)$$

其中,  $h_t^+$  表示  $t$  时刻经正向 GRU 得到的特征向量,  $h_t^-$  表示经反向 GRU 得到的特征向量, 二者连接得到文本的特征向量表示。

##### 3.2.3 自注意力层(self-attention layer)

自注意力机制的主要作用是对序列分析后的特征进行初步筛选, 突出和保留与任务相关性更高的特征。具体表现形式为: 通过考虑全局信息, 计算得到词语的权重值  $\alpha$ , 然后将各词的权重与各时刻的特征输出表示进行加权求和, 得到突出重点的新的特征表示  $H_t$ 。该过程如式(8)所示:

$$H_t = \sum \alpha_i h_i \quad (8)$$

其中,  $\alpha_i$  表示特征权重, 且满足  $\sum \alpha_i = 1$ 。

##### 3.2.4 多粒度卷积层(multi-scale CNN layer)

本层接收自注意力层输出的文本特征, 选取不同大小的卷积核对文本特征进行进一步的提取, 并采用 Relu 激活函数。相比早期的 Sigmoid 函数, Relu 能加快模型训练收敛的速度, 同时可以更有效地实现梯度下降和反向传播, 避免了梯度爆炸和梯度消失的问题。抽取特征的过程如式(9)所示:

$$c_i = f_{\text{Relu}}(w \cdot x_{i:i+h-1} + b) \quad (9)$$

其中,  $w \in R^{h \times m}$  表示卷积核的权重,  $h \times m$  表示卷积核窗口的粒度,  $b$  表示偏置量,  $f_{\text{Relu}}$  为激活函数。

##### 3.2.5 基于自注意力的池化层(attentional pooling layer)

在通道卷积层中, 模型得到了包含局部特征的特征图。为了进一步从中寻找到对最终情感极性分类结果影响最大的



因素,一般会采用池化方法。如 Max-Pooling,Ave-Pooling 等池化方法的作用可理解为一种形式的降采样,同时使用局部最大值或者局部均值来代表采样部分,减少训练数据量和模型参数。本文提出使用自注意力机制来取代传统的 Pooling 层,以提高特征的提取能力,同时也可以起到降维约参的作用,降低计算消耗。本层的计算过程如式(10)所示:

$$P_i = \sum \alpha_i' c_i \tag{10}$$

其中, $\alpha_i'$ 表示特征权重,且满足  $\sum \alpha_i' = 1$ 。

3.2.6 全连接层(dense layer)

在卷积层中得到文本数据的特征图,再经自注意力降维层后进行提取,获得了对情感分类影响最大的局部特征序列。本层的作用是将特征序列输入全连接层进行特征融合,再通过分类层进行情感极性分类。其运算过程为:序列经全连接层处理融合,得到特征序列 $D^{final}$ ;分类层使用 Softmax 对所有的局部特征进行综合分析,将输入 $D^{final}$ 转化为两种情感极性的概率分布,计算式如式(11)所示:

$$p_i = \text{Softmax}(\mathbf{W} \cdot D^{final} + b) \tag{11}$$

其中, $p_i$ 为情感极性的概率分布, $\mathbf{W}$ 为 Softmax 的权重矩阵, $b$ 为偏移量。

4 实验与分析

4.1 实验设置

4.1.1 实验环境设置

训练模型时使用的操作系统为 Ubuntu 18.04,采用 Python3.7+TensorFlow1.14 的深度学习框架。采用 TensorFlow1.14 而不是更新的 TensorFlow2.x 系列,主要是考虑到前者的稳定性更好,而且代码各子模块的适配程度更加紧密。实验的硬件配置如表 1 所列。

表 1 实验环境配置

Table 1 Experimental environment configuration	
Hardware	Configuration
CPU	Intel Core i7-10700K main frequency 3.8GHz
Memory/GB	16
GPU	Nvidia RTX-2080TI video memory 11GB

4.1.2 实验数据集

为检验本文模型在中文语料环境中的情感极性分类性能,本文使用 ChineseNLPcorpus 组织提供的中文情感分类数据集 online\_shopping\_10\_cats 和中科院计算所谭波收集的酒店评论数据集这两个数据集进行实验。

数据集 online\_shopping\_10\_cats 包含 10 类线上交易,2 种情感倾向性标注,0 表示负倾向性情感,1 表示正倾向性情感。实验采用的训练数据有 52783 条,测试数据有 10000 条,对测试数据进行平衡化处理,使其正极性、负极性数据各 5000 条。具体示例如表 2 所列。

表 2 online\_shopping\_10\_cats 数据集统计

Table 2 Statistics of online_shopping_10_cats dataset			
Emotional tendency	Amount	Average length	Mark
Positive	31 727	68.78	1
Negative	21 056	54.97	0

酒店评论数据集包含的正倾向性情感数据和负倾向性情

感数据分别为 7000 条和 3000 条。本次实验中的训练数据有 9000 条,测试数据有 1000 条。酒店评论数据集的具体参数如表 3 所列。

表 3 酒店评论数据集的统计

Table 3 Statistics of hotel review dataset			
Emotional tendency	Amount	Average length	Mark
Positive	7 000	112.11	1
Negative	3 000	169.06	0

4.1.3 实验参数设置

采用维度适中的词嵌入方式,能够在尽可能充足保留词汇深层次含义的同时降低训练开销,减少计算量。本文采用 Li 等<sup>[23]</sup>在中文语料环境中训练好的 300 维的词向量模型 Chinese-Word-Vectors,该模型为 Word2vec 的衍生版本。

为充分提取文本特征,本文采用 4 种不同大小的卷积核来进行不同尺度的上下文信息提取。为避免出现过拟合现象,模型加入 Dropout 机制,具体参数配置如表 4 所列。

表 4 模型参数配置

Table 4 Model parameter configuration	
Hyper parameter	Configuration
Word vector dimension	300
Size of convolution kernel	(2,3,4,5)
Layer of BGRU	128
Batch size	50
Learning rate	0.0012
Dropout rate	0.5
Optimizer	Adam

根据数据集数据的具体特征,对数据进行有区别的预处理。数据集的具体参数如表 5 所列。

表 5 数据集处理

Table 5 Dataset processing		
Hyper parameter	online_shopping_10_cats	Hotel review
Word amount	30.86	67.96
Sequence length	40	80
Truncation method	Tail	Tail
Filling method	Tail	Tail

4.2 评估标准与对比实验

4.2.1 评估方法

本文采用的评估参数包括准确率(Accuracy,ACC)和交叉熵损失函数(Cross Entropy Loss,CEL)。

ACC 的计算式如式(12)所示:

$$ACC(i) = \frac{T_i}{N} \tag{12}$$

其中, $T_i$ 表示正确分类的数据条数, $N$ 表示数据总条数。

损失函数 CEL 刻画的是实际输出(概率)与期望输出(概率)的距离,可理解为 CEL 的值越小,两个概率分布就越接近,模型的拟合程度就越高。

CEL 的计算式如式(13)所示:

$$CEL = -\frac{1}{N} \sum [y \ln a + (1-y) \ln (1-a)] \tag{13}$$

其中, $a$ 表示真实输出, $y$ 表示期望输出, $N$ 表示文本总数。

4.2.2 对比实验

为了证明模型的有效性,将本文模型与当前性能较好的

情感分析模型进行比较。下文给出了对比模型及其简介。

(1)LSTM。使用 LSTM 对文本序列进行提取,本文的对比实验以 Zaremba 等<sup>[24]</sup>提出的网络结构为基础,加上部分适应性调整。

(2)Bi-LSTM<sup>[25]</sup>。结合上下文信息,提高对文本序列特征进行提取的能力。

(3)GRU<sup>[26]</sup>。使用较简洁的 GRU 结构,以提升模型的训练速度。

(4)BGRU。使用双向 GRU,增强对上下文信息的结合。

(5)ATT-BiLSTM<sup>[27]</sup>。使用注意力机制对 BiLSTM 网络的输出进行重要程度区分。

(6)textCNN<sup>[28]</sup>。使用 CNN 网络对文本局部特征进行提取。

(7)multi-textCNN<sup>[29]</sup>。使用多粒度不同卷积核 CNN 网络,以充分提取文本特征。

(8)multiCNN-ATT。使用不同尺寸的卷积核对文本特征进行提取,并采用注意力机制对特征进行重要性划分。

(9)HATT-BLSTM-MGCNN。与本文模型的区别在于使用 Bi-LSTM 网络。

(10)C-HAN-character<sup>[30]</sup>。基于 Word2vec 中文字级别的词向量,融合卷积神经网络与层次化注意力网络的文本情感分析模型。

(11)character-SATT-BiLSTM<sup>[1]</sup>。使用字向量表示方法对文本进行向量化表示,其是结合 Self-Attention 和 BiLSTM 网络的短文情感分析算法。

(12)HATT-BGRU。消融实验,与本文提出的模型相比,去除了多粒度卷积层。

4.3 结果与分析

4.3.1 测试结果

各模型准确度如表 6 所列。

表 6 模型准确度汇总  
Table 6 Summarizes the accuracy of each model

(单位:%)		
Model	online_shopping_10_cats	Hotel review
LSTM	91.58	84.09
GRU	91.79	84.76
Bi-LSTM	91.86	85.76
BGRU	92.29	86.43
ATT-BiLSTM	92.38	88.22
textCNN	91.11	87.92
multi-textCNN	91.87	89.12
multiCNN-ATT	92.35	91.75
HATT-BLSTM-MGCNN	92.40	92.53
character-SATT-BiLSTM	—	91.67
C-HAN-character	—	92.34
HATT-BGRU	92.33	90.26
本文模型	92.94	92.75

因为选用了相同的数据集,所以部分算法采用了现有文献中的结果<sup>[1,30]</sup>。

4.3.2 准确率分析

如表 6 所列,由实验结果可得,本模型在 online\_shopping\_10\_cats 数据集上取得了更高的情感分类准确性,相比其他实

验,最优组也有大于 0.5%的提升,考虑到 92%的准确性水平,这种程度的提升是可接受的。

本文模型在酒店评论数据集上取得了 92.75%的准确性,也为该组的最佳结果。实验结果证明,本文模型在中文语料环境中具有普遍性的优异性能。

同时,为检验模型结构的合理性,本文对模型进行了消融实验。实验结果证明,多粒度卷积神经网络在提高模型分类准确度方面具有一定的作用,特别是当文本数据较长时,如酒店数据集,其对模型性能的提升效果更加明显。本文认为,这一现象是卷积神经网络能够降低数据维度、提高模型对局部特征的提取能力所致。

回顾实验数据,online\_shopping\_10\_cats 数据集和酒店评价数据集的数据条目处于  $10^4 \sim 10^5$  之间,均属于中等规模的数据集。一方面,结构复杂、参数更多的 LSTM 网络结构在训练过程中更容易出现过拟合现象,导致准确率下降;另一方面,正反双向结构对于文本的前后序列特征提取能力更强,这一点在实验结果上体现得较明显。无论是 LSTM 还是 GRU,在使用双向结构后准确度均有一定的提升。对于使用 CNN 结构的模型,多粒度的处理方法比单一卷积核的方法在两种数据集上的准确性分别高出了 0.76%和 1.2%。这证明了在情感分类任务上使用多种尺度的卷积核进行特征提取的有效性。相比传统的 Pooling 方法,自注意力机制的引入能够进一步提高模型对关键特征的抽取和保留能力,从而提高模型分类的精度。

无论是本文模型还是 C-HAN-character 模型,其性能相比只使用循环神经网络或卷积神经网络结构的模型,在准确度上都有提高,这足以说明两种结构的组合是能够提高模型性能的。

4.3.3 回调参数分析

对本文模型训练过程中的各种参数进行分析。如图 2 所示,损失函数随着训练轮次的增加迅速下降,趋向收敛。




图 2 本文模型的训练损失函数  
Fig. 2 Training loss function of our model

在 online\_shopping\_10\_cats 数据集上,6 轮训练后,模型 Trian Loss 已降至 0.10 以下,第 13 轮后,损失函数的下降趋势较缓,第 18 轮后损失函数稳定在 0.0080 附近,模型达到收敛。在酒店评论数据集上,模型的损失函数下降得更快,在第 8 轮后,模型便趋向于收敛,值得注意的是,在第 15 轮后,模型的交叉熵损失函数下降至 0.000 1 以下,即模型对数据集的拟合效果出色。

由图 3 可知,在 online\_shopping\_10\_cats 数据集上,模型的测试准确性很快便趋于稳定,随着实验轮次的增加,本文

模型对训练数据的拟合程度逐渐提高,但测试准确性没有明显变化。




图3 本文模型在 online\_shopping\_10\_cat 数据集上的准确率

Fig.3 Accuracy of our model on online\_shopping\_10\_cat dataset

如图4所示,对于酒店评论数据,模型的测试准确性在开始的5轮训练中逐渐提高,在第11轮后模型的性能趋向于稳定。




图4 本文模型在酒店评论数据集的准确率

Fig.4 Accuracy of our model on the hotel review dataset

综合上述实验结果表明,本文模型采用较少的训练轮次便可达到稳定,收敛速度快且性能较优。

**结束语** 针对基于中文语料的文本情感分析任务,本文提出了一种融入自注意力机制的深度学习情感分析方法。该模型采用循环神经网络结构来提取文本的序列特征,然后使用自注意力机制突出其中与情感分类相关的特征,再将其输入使用多粒度的卷积神经网络来进行更高层次的特征提取,并且使用自注意力机制来实现池化功能,更好地强调了与分类更相关的语义信息,最终实现了文本的情感极性判断。在中文语料环境中的两种典型数据集上的实验证明:本文模型较目前的主流方法,在情感极性预测的准确性上有一定提高。此外,本文通过消融实验,证明了该模型结构的合理性。

通过组合使用卷积神经网络和循环神经网络,本文模型在两种数据集上均取得了不错的成绩。但是现实中,往往会存在目标领域缺乏高质量训练数据的情况,如何从已有的训练数据集出发,提高深度学习模型解决跨领域问题的能力值得进一步的研究。

## 参考文献

[1] WU X H, CHEN L, WEI T T, et al. Sentiment Analysis of Chinese Short Text Based on Self-Attention and Bi-LSTM[J]. Journal of Chinese Information Processing, 2019, 33(6): 100-107.

[2] KALCHBRENNER N, GREFFENSTETTE E, BLUNSOM P. A convolutional neural network for modelling sentences[C]// Proceedings of the 52nd Annual Meeting of the Association for

Computational Linguistic Stroudsburg, PA: ACL, 2014: 655-665.

[3] KIM Y. Convolutional neural networks for sentence classification[C]// 2014 Conference on Empirical Methods in Natural Language Processing, Doha, 2014: 1746-1751.

[4] LIU Y. Research on english textual entail recognition based on lstm[D]. Harbin: Harbin Institute of Technology, 2016.

[5] WANG S, JIANG J. Learning natural language inference with LSTM[C]// Proceedings of the Human Language Technologies: The 2016 Annual Conference of the North American Chapter of the Association for Computational Linguistics, Association for Computational Linguistics, 2016: 1442-1451.

[6] LI R, LIN Z, LIN H, et al. Text Emotion Analysis: A Survey [J]. Journal of Computer Research and Development, 2018, 55(1): 30-52.

[7] PANG B, LEE L, VAITHYANATHAN S. Sentiment classification using machine learning techniques[C]// Proceedings of the 2002 Conference on Empirical Methods in Natural Language Processing, Pennsylvania, Stroudsburg: ACL, 2002: 79-86.

[8] HU M Q, LIU B. Mining and summarizing customer reviews [C]// Proceedings of the 10th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, New York: ACM, 2004: 168-177.

[9] YAO T F, LOU D C. Research on semantic orientation analysis for topics in Chinese sentences[J]. Journal of Chinese Information Processing, 2007, 21(5): 73-79.

[10] DAI H L, ZHONG G J, YOU Z M, et al. Public Opinion Sentiment Big Data Analysis Ensemble Method Based on Spark[J]. Computer Science, 2021, 48(9): 118-124.

[11] BOWMAN S R, ANGELI G, POTTS C, et al. A large annotated corpus for learning natural language inference[C]// Proceedings of the 2015 Conference on Empirical Methods in Natural Language Processing, 2015: 632-642.

[12] ROCKTÄSCHEL T, GREFFENSTETTE E, HERMANN K M, et al. Reasoning about entailment with neural attention[J]. arXiv: 1509.06664, 2015.

[13] XIAO Z, LIANG P J. Chinese sentiment analysis using bidirectional LSTM with word embedding[C]// Proceedings of the 2nd International Conference on Cloud Computing and Security, Berlin: Springer, 2016: 601-610.

[14] PAPPAS N, POPESCU-BELIS A. Multilingual hierarchical attention networks for document classification[C]// Proceedings of the 15th Conference of the European Chapter of the Association for Computational Linguistics (EACL), 2017: 1015-1025.

[15] LIU L F, YANG L, ZHANG S W, et al. Convolution neural networks for Chinese microblog sentiment analysis[J]. Journal of Chinese Information Processing, 2015, 29(6): 159-165.

[16] ZHANG J, DUAN L G, LI A P, et al. Fine-grained Sentiment Analysis Based on Combination of Attention and Gated Mechanism[J]. Computer Science, 2021, 48(8): 226-233.

[17] YUAN H J, ZHANG X, NIU W H, et al. Sentiment Analysis Based on Multichannel Convolution and Bidirectional GRU with Attention Mechanism[J]. Journal of Chinese Information Pro-

cessing, 2019, 33(10):109-118.

[18] WANG L Y, LIU C H, CAI D B, et al. Chinese text sentiment analysis based on character-level two-channel composite network[J]. Application Research of Computers, 2020, 37 (9): 2674-2678.

[19] MNH V, HEES N, GRAVES A. Recurrent models of visual attention[C]//Advances in Neural Information Processing Systems. Montreal, Canada: NPIS, 2014: 2204-2212.

[20] BAHDANAU D, CHO K, BENGIO Y. Neural machine translation by jointly learning to align and translate[J]. arXiv: 1409. 0473, 2014.

[21] CHENG S Y, GUO Z Y, LIU W, et al. Research on Multi-granularity Sentence Interaction Natural Language Inference Based on Attention Mechanism[J]. Journal of Chinese Computer Systems, 2019, 40(6): 1215-1220.

[22] CHO K, VAN MERRIENBOER B, GULCEHRE C, et al. Learning phrase representations using RNN encoder-decoder for statistical machine translation [C] // Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing. Stroudsburg, PA: Association for Computational Linguistics, 2014: 1724-1734.

[23] LI S, ZHAO Z, HU R, et al. Analogical Reasoning on Chinese Morphological and Semantic Relations[C]//Meeting of the Association for Computational Linguistics, 2018.

[24] ZAREMBA W, SUTSKEVER I, VINYALS O. Recurrent neural network regularization[J]. Eprint Arxiv, 2014.

[25] XIAO Z, LIANG P J. Chinese sentiment analysis using bidirectional LSTM with word embedding[C]//Proc of the 2nd International Conference on Cloud Computing and Security. Berlin: Springer, 2016: 601-610.

[26] GAO Y, GLOWACKA D. Deep gate recurrent neural network [J]. arXiv:1604. 02910, 2016.

[27] WANG Y Q, HUANG M, ZHAO L, et al. Attention-based LSTM for aspect-level sentiment classification [C] // Proceedings of Conference on Empirical Methods in Natural Language Processing. 2016: 606-615.

[28] WANG Y H, ZHANG C Y, ZHAO B L, et al. Sentiment analysis of twitter data based on CNN[J]. Journal of Data Acquisition and Processing, 2018, 33(5): 921-927.

[29] GUO B, ZHANG C X, LIU J M. Improving text classification with weighted word embeddings via a multi-channel TextCNN model[J]. Neurocomputing, 2019, 363: 366-374.

[30] CHENG Y, YE Z M, WANG M W, et al. Chinese Text Sentiment Orientation Analysis Based on Convolution Neural Network and Hierarchical Attention Network[J]. Journal of Chinese Information Processing, 2019, 33(1): 133-142.



**HU Yan-li**, born in 1979, associate professor, is a member of China Computer Federation. Her main research interests include text mining and knowledge engineering.

(责任编辑:喻黎)